Práctica 1. Definición del proyecto semestral

OBJETIVO **Desarrollar la propuesta del proyecto semestral mediante el entendimiento profundo del problema y sus posibles impactos y aplicaciones, y conjuntando actividades de selección, carga inicial y exploración de conjuntos de datos abiertos.**

PROCEDIMIENTO: **Defina el alcance preliminar del proyecto y realice un primer reconocimiento de dos conjuntos de datos obtenidos del Portal de Datos Abiertos de la Ciudad de México. Revise los materiales de clase correspondientes a «Exploración básica de datos con Tableau», «Limpieza de datos» y «CRISP-DM».**

1. **Explore las categorías disponibles:**

   en el Portal de Datos Abiertos de la Ciudad de México https://datos.cdmx.gob.mx/



2. Seleccione DOS conjuntos de datos que cumplan con las condiciones siguientes:

a) Cobertura temporal: cada conjunto debe contener, como mínimo, un año de registros. Si no es posible procesar el conjunto completo, reduzca su tamaño mediante filtros temporales; preferentemente, conserve el año más reciente.

b) Sobre el periodo de tiempo en el dataset, debe incluir como mínimo, los atributos «año» y «mes», o una fecha a partir de la cual puedan derivarse los respectivos análisis.

c) Dimensión espacial: debe incluir, como mínimo, la alcaldía y/o las coordenadas geográficas (latitud y longitud), o información que permita obtenerlas.

d) Volumen de datos: debe contener más de 99,999 y menos de 4 000,000 de registros. Si el volumen original excede la capacidad de procesamiento disponible, aplique filtros hasta cumplir este intervalo. Importe los datos en el manejador de bases de datos de su preferencia y documente el número exacto de registros (aspecto crítico).

e) En caso de incluir o usar otra fuente de datos debe consultar al profesor (aspecto crítico).

3. Explique en el reporte cómo cada conjunto de datos satisface los requisitos del punto 2.

4. Identifique y describa las dimensiones temáticas de cada conjunto de datos. Verifique si existe un diccionario de datos y utilícelo para interpretar correctamente los atributos; por ejemplo: tipo de incidente vial o clasificación del origen del reporte (aspecto crítico).

5. Describa con precisión la granularidad temporal y espacial (aspecto crítico). En la dimensión temporal, indique si los datos se registran por año, mes, día, hora, minuto o segundo. En la dimensión espacial, señale el nivel disponible: alcaldía, colonia, vialidad, coordenada u otro.

6. Proponga un caso de estudio en el que uno de los conjuntos seleccionados pueda complementarse con datos del perfil poblacional de la Ciudad de México (aspecto crítico). Por ejemplo, los incidentes viales podrían relacionarse con la población residente de cada alcaldía.

7. Justifique la selección de los conjuntos de datos (aspecto crítico): relevancia del fenómeno, calidad y disponibilidad de la información, cobertura temporal y espacial, y posibilidades de integración.

8. Defina el problema que desea estudiar y delimite el alcance preliminar del proyecto. Exprese con claridad qué conocimiento espera obtener mediante el análisis de los datos (aspecto crítico).

9. Realice un análisis exploratorio básico en Tableau. Responda las preguntas siguientes aplicando criterios de filtrado y visualización pertinentes. Incorpore las gráficas, los resultados y una breve interpretación en el reporte.

a) ¿Cuál es la distribución de la dimensión categórica o temática más importante del fenómeno descrito? Ejemplo: distribución general de los incidentes viales por tipo.

b) ¿Cómo se distribuye el fenómeno en el tiempo? Explore tantos niveles de granularidad como permitan los datos. Ejemplo: distribución anual y mensual de los incidentes viales.

c) ¿Existen valores atípicos, faltantes, duplicados o inconsistentes? Contraste sus hallazgos con el diccionario de datos.

d) ¿Fue posible procesar todos los registros originales? Si aplicó filtros o reducciones por tiempo u otra variable, explique y justifique el procedimiento.

10. Elabore el documento de diagnóstico preliminar con la estructura siguiente:

- **Autores.**
- **Introducción: contexto del problema y propuesta preliminar de solución.**
- **Desarrollo: resultados de los puntos 1 al 9, con evidencia e interpretación.**
- **Acta constitutiva del proyecto.**
- **Reporte del estado de los datos: exploración preliminar, calidad, granularidad y limitaciones.**
- **Conclusiones: valoración de la factibilidad técnica y analítica del proyecto.**

11. Prepare una presentación de 5 a 7 diapositivas con la información más importante del proyecto, explica con claridad y economía de palabras.

12. Anexe un archivo ZIP que contenga las fuentes de datos utilizadas, los archivos de trabajo de Tableau y cualquier recurso necesario para reproducir la exploración.

EJEMPLO DE ACTA CONSTITUTIVA

ACTA CONSTITUTIVA DEL PROYECTO DE DATOS

NOTA: EL TEXTO ES BREVE PARA ILUSTRAR LO QUE DEBE CONTENER NO SIGNIFICA QUE SE REDUZCA A LA MISMA CANTIDAD DE INFORMACIÓN Y CONTENIDOS

1. DATOS GENERALES DEL PROYECTO

- **Nombre del Proyecto: Análisis Predictivo de Calidad del Aire en la Ciudad de México**
- **Institución/Organización: Laboratorio de Datos Urbanos**
- **Fecha de Constitución: 12 de marzo de 2025**
- **Duración del Proyecto: 12 meses**
- **Responsables del Proyecto:**
  - **Dr. Juan Pérez (Coordinador del Proyecto)**
  - **Mtra. Ana Gómez (Analista de Datos)**
  - **Ing. Roberto Zagal (SPONSOR)**
- **Patrocinador o unidad financiera: Fondo MISTI IPN**

---

2. OBJETIVOS DEL PROYECTO

- **Objetivo principal: desarrollar un modelo predictivo de la calidad del aire en la Ciudad de México mediante técnicas de inteligencia artificial y datos abiertos.**
- **Objetivos secundarios:**
  - **Implementar una plataforma de monitoreo en tiempo real.**

- **Identificar patrones de contaminación a nivel de calle.**
- **Desarrollar recomendaciones para apoyar la formulación de políticas públicas.**

---

3. ANÁLISIS DEL CONTEXTO DEL PROBLEMA (BUSINESS UNDERSTANDING)

- **Antecedentes: La calidad del aire en la Ciudad de México es un problema crítico que afecta la salud pública y la movilidad urbana. Existen múltiples fuentes de datos ambientales, pero su integración y análisis predictivo aún son limitados.**
- **Áreas involucradas:**
  - **Secretaría del Medio Ambiente (SEDEMA)**
  - **Secretaría de Movilidad (SEMOVI)**
  - **Instituciones de investigación y universidades**
- **Problema por resolver: falta de herramientas de monitoreo con suficiente granularidad para apoyar decisiones informadas orientadas a reducir contaminantes.**
- **Soluciones actuales: se utilizan estaciones fijas de monitoreo; sin embargo, su cobertura espacial y temporal es limitada.**
- **Productos y criterios de éxito del proyecto:**
  - **Precisión del modelo predictivo superior al 85 %.**
  - **Desarrollo de una plataforma de consulta pública y accesible.**
  - **Generación de reportes con interpretaciones validadas.**

---

4. INVENTARIO DE DATOS

- **Fuentes de datos:**
  - **Red de sensores Flatburn: Sensores móviles que recopilan información en tiempo real sobre partículas contaminantes (PM 1.0, PM 2.5, PM 10), temperatura, humedad y presión atmosférica.**
  - **Datos abiertos de la SEDEMA: Registros históricos de calidad del aire obtenidos de estaciones de monitoreo fijas en la Ciudad de México.**
  - **Datos meteorológicos del SMN: Información sobre temperatura, velocidad del viento, humedad y precipitaciones.**
  - **Datos de tráfico de SEMOVI: Flujos vehiculares y patrones de congestión en las principales avenidas de la ciudad.**
- **Características de los datos:**
  - **Sensores Flatburn: Datos en tiempo real con resoluciones espaciales de hasta 10 metros.**
  - **Datos de SEDEMA: Históricos desde 2010, con registros horarios de contaminantes.**

    - **Datos meteorológicos: Predicciones y datos observados en intervalos de 3 horas.**
    - **Datos de tráfico: Registros de movilidad obtenidos de cámaras y sensores viales con resolución de minutos.**
- **Ubicación y formatos de los datos:**
    - **Datos de sensores Flatburn: bases de datos en la nube con acceso mediante una API.**
    - **Datos de SEDEMA y SEMOVI: archivos descargables en formatos CSV y JSON desde portales gubernamentales.**
    - **Datos meteorológicos: acceso mediante la API del Servicio Meteorológico Nacional.**

---

5. DEFINICIÓN DE LOS OBJETIVOS DE MINERÍA DE DATOS

- **Objetivos técnicos:**
    - **Construir un modelo de predicción basado en redes neuronales.**
    - **Evaluar la correlación entre las variables ambientales y el tráfico vehicular.**
- **Criterios de éxito de la minería de datos:**
    - **Precisión superior al 85 %.**
    - **Capacidad de generalización a distintas zonas de la ciudad.**
    - **Interpretabilidad del modelo para apoyar la toma de decisiones.**

---

6. PLAN DE TRABAJO Y METODOLOGÍA

- **Fases del proyecto:**
    1. **Comprensión del problema (marzo-abril de 2025).**
    2. **Comprensión de los datos (mayo-junio de 2025).**
    3. **Preparación de los datos (julio-agosto de 2025).**
    4. **Modelado (septiembre-octubre de 2025).**
    5. **Evaluación (noviembre de 2025).**
    6. **Despliegue (diciembre de 2025-febrero de 2026).**

---

7. ANÁLISIS DE RIESGOS Y PLANES DE CONTINGENCIA

- **Riesgos identificados:**
    - **Riesgos técnicos: incompatibilidad entre las fuentes de datos.**
    - **Riesgos organizacionales: falta de colaboración entre las instituciones.**
    - **Riesgos financieros: reducción del financiamiento disponible.**
- **Planes de mitigación:**

- **Integración de datos mediante API y procesos ETL.**
- **Establecimiento de acuerdos de colaboración con entidades gubernamentales.**
- **Búsqueda de financiamiento adicional mediante convocatorias.**

---

8. APROBACIÓN Y FIRMA

Las partes involucradas acuerdan la constitución formal del proyecto y su alineación con la metodología CRISP-DM.

Nombre	Cargo	Firma	Fecha
Dr. Juan Pérez	Coordinador del Proyecto	_____	12/03/2025
Mtra. Ana Gómez	Analista de Datos	_____	12/03/2025
Ing. Roberto Zagal	SPONSOR	_____	12/03/2025

FIN DEL EJEMPLO DE ACTA CONSTITUTIVA

EJEMPLO DE REPORTE EXPLORATORIO DE DATOS

NOTA 1: DEBE COLOCAR GRAFICAS Y EXPLICACIÓN DE LA INTERPRETACIÓN DE CADA UNA

NOTA 2: EL TEXTO ES BREVE PARA ILUSTRAR LO QUE DEBE CONTENER NO SIGNIFICA QUE SE REDUZCA A LA MISMA CANTIDAD DE INFORMACIÓN Y CONTENIDOS

- **Resumen general: se analizaron los datos disponibles de calidad del aire, tráfico y meteorología para identificar patrones y anomalías relevantes.**
- **Estadísticas generales:**
  - **Concentración promedio de PM2.5 durante los últimos cinco años: 32 µg/m³.**
  - **Concentración máxima registrada: 95 µg/m³ (invierno de 2023).**
  - **Variabilidad diaria de PM10: de 15 a 60 µg/m³.**
  - **Correlación entre el tráfico y PM2.5: 0.78 (relación alta).**
- **Hallazgos clave:**
  - **Se observan picos de contaminación durante los periodos de tráfico intenso (de 7:00 a 10:00 y de 18:00 a 21:00).**
  - **La contaminación aumenta en días con baja velocidad del viento (< 3 m/s).**
  - **Las estaciones fijas de monitoreo subestiman la contaminación en zonas con tráfico intenso.**
  - **La calidad del aire mejora significativamente después de lluvias intensas.**